A geração Z bebe menos?

Consumo abusivo de álcool por geração nas capitais brasileiras, Vigitel 2010-2024

MVP de pipeline de dados em nuvem (Databricks) · PSP8, Prof. André Luiz Marques Serrano, EPR/FT/UnB

Guilherme Augusto Fontes Cunha

Por que este tema

“A geração Z bebe menos, e isso está dando prejuízo à indústria do álcool.”

A afirmação que circula nas notícias de mercado e motivou o trabalho

1 Verificar

Todos temos percepções pessoais sobre como os jovens bebem. Quis testar a manchete com dados oficiais, e não com impressões.

2 Entender quem

Não basta saber se bebem menos: interessa saber quais jovens, de que sexo e classe, e se a mudança é da geração.

3 Ir além

O Vigitel pergunta muito mais que álcool. Os correlatos abrem outras investigações, com a metodologia certa.

O problema de negócio

Decisão 1: nicho ou massa?

Se só os jovens mais escolarizados bebem menos, a linha sem álcool é um produto premium, de nicho. Se a queda atinge todas as classes, é mercado de massa.

Decisão 2: estrutural ou fase?

Se a geração Z leva o hábito para a vida adulta, o investimento é de longo prazo. Se só adia o consumo, é uma fase de idade.

Decisor: área de estratégia e portfólio de uma empresa de bebidas

- Errar para nicho numa tendência ampla: perder mercado.
- Errar para massa numa tendência restrita: investir em distribuição sem demanda.
- Interesse secundário: saúde pública (prevenção por geração, sexo e classe).

Hipótese e perguntas

Na mesma idade (18 a 24 anos), o consumo abusivo de álcool diminui de uma geração para a seguinte, nos dois sexos e em todas as faixas de escolaridade, e isso não é uma tendência geral da população.

P1

Quanto cada geração difere da anterior, aos 18-24?

P2

A diferença ocorre em todas as faixas de escolaridade?

P3

É efeito de geração ou da época?

P4

É igual entre homens e mulheres?

P5

Quais capitais concentram as maiores diferenças?

Consumo abusivo = 5+ doses (homens) ou 4+ doses (mulheres) numa ocasião, nos últimos 30 dias (indicador oficial do Vigitel).

Roteiro

1. **Pré-análise** — conhecer a base antes de tratar
2. **Decisões** — D1 a D14, com alternativas
3. **Pipeline** — bronze, silver, gold e qualidade
4. **Resultados** — P1 a P5, robustez e veredito
5. **Discussão** — o que fazer com isso
6. **Limitações** — até onde os números vão

Todas as figuras vêm do próprio pipeline (resultados/figuras) ou do relatório de análise exploratória; as capturas, da execução no Databricks Free Edition em 21/10/2026.

Pré-análise

Conhecer a base antes de tratar: três versões da análise exploratória (v1 a v3)

O processo da pré-análise

1 — Fonte

dicionário, nota metodológica, licença e SHA-256 do arquivo

2 — Vazios

separar pulo de questionário, variável inexistente e falta real

3 — Amostra e pesos

jovens por edição e escala do peso

4 — Método

rupturas: 2010, sem 2022, celular, filtro de 2024

5 — Prévia

as cinco perguntas, ainda comparando anos

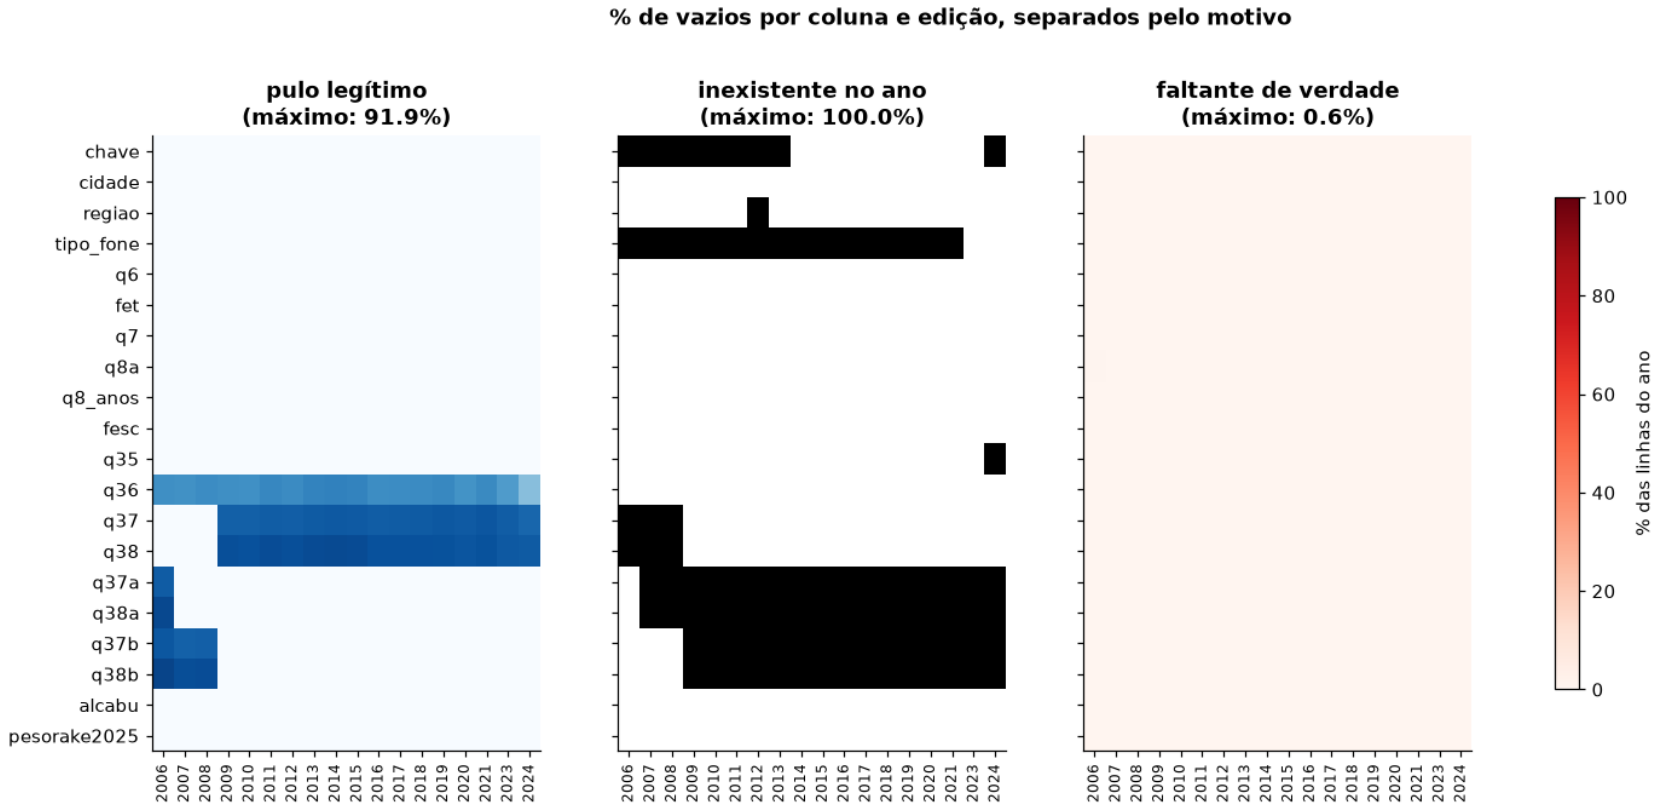
6 — Decisões

objetivo v2 por geração e D1 a D14

Como foi conduzida

Notebooks gerados por script, uma versão por rodada (v1 a v3). Os comentários do autor sobre cada versão foram acumulados e aplicados juntos na seguinte, e as decisões de tratamento ficaram com o autor, com alternativas e motivos registrados.

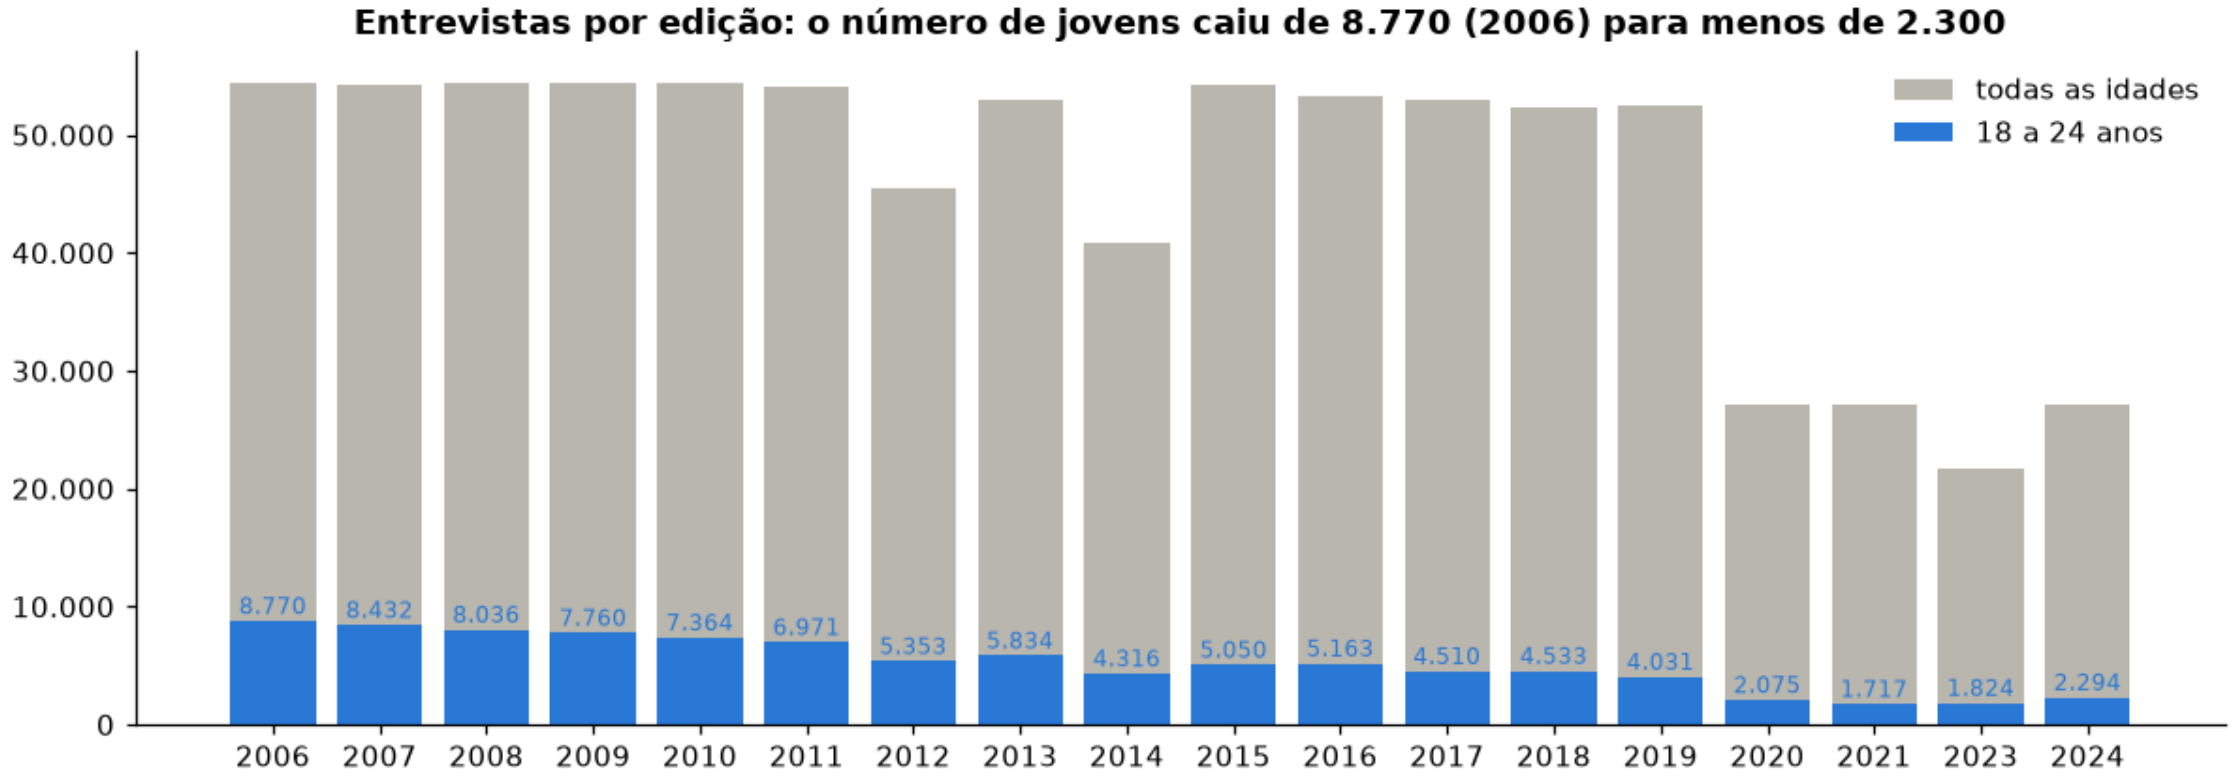
Quase todo vazio é pulo de questionário, e não dado perdido



- Pulo legítimo (azul): quem não bebe não responde às doses
- Inexistente no ano (preto): a pergunta não existia naquela edição
- **Falta real: no máximo 0,6% de uma coluna**

Consequência: nada a imputar. Os vazios viram regra de consistência (pulo conferido em 100% dos casos) e não tratamento.

Os jovens entrevistados encolheram ao longo da série

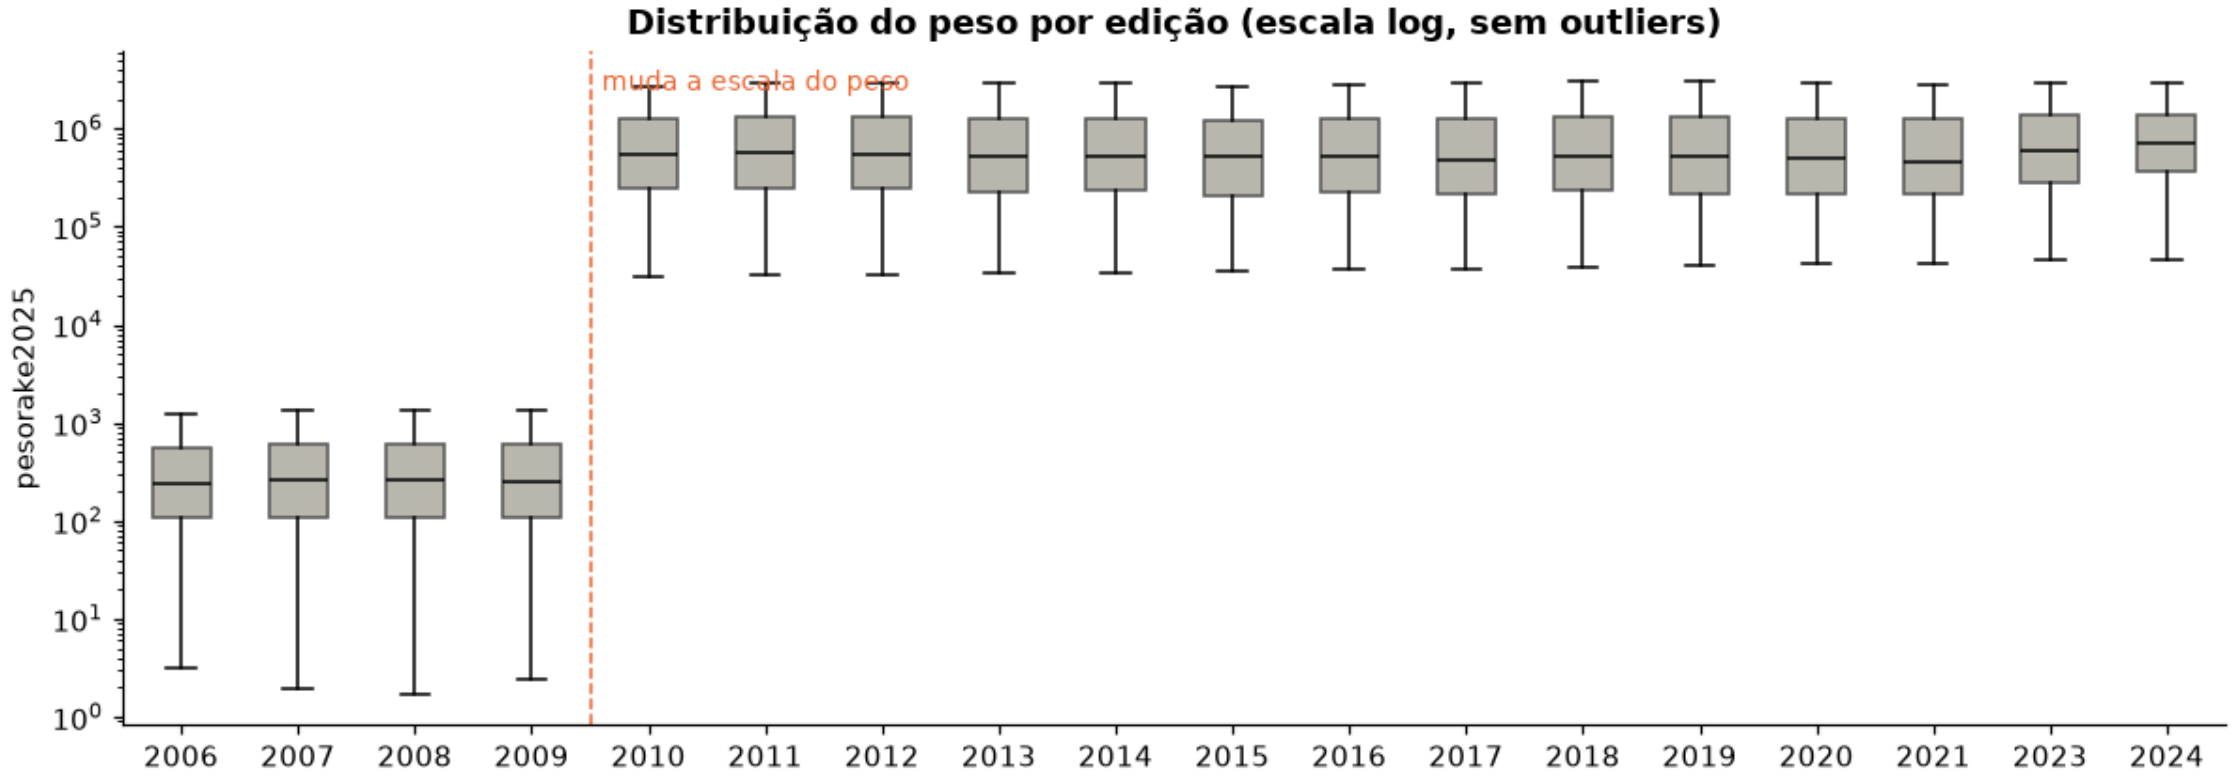


8.770 → 2.294

jovens de 18 a 24 anos entrevistados em 2006 e em 2024

- 2020-2021: pandemia, amostra pela metade (D11)
- **Um ano isolado tem margem de ±3 p.p.: juntar as edições de cada geração (D3)**

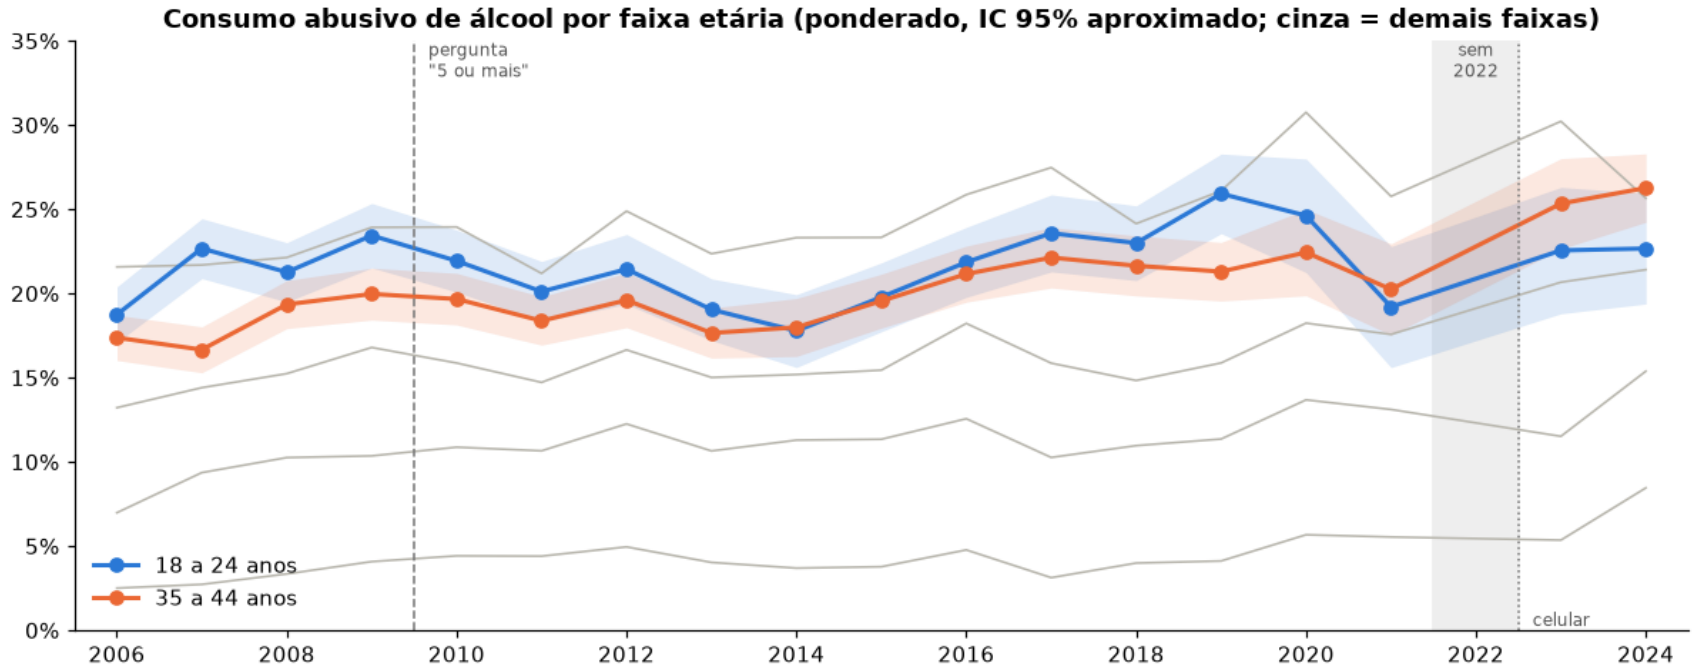
O peso amostral muda de escala em 2010



Decisão D4: normalizar o peso de cada edição para somar 1

Sem isso, ao juntar edições, os anos com peso maior dominariam a geração. Com a normalização, cada ano conta igual.

Comparar anos mistura comportamento com método



2010

a pergunta de doses passa a ser “5 ou mais” (D5)

2022

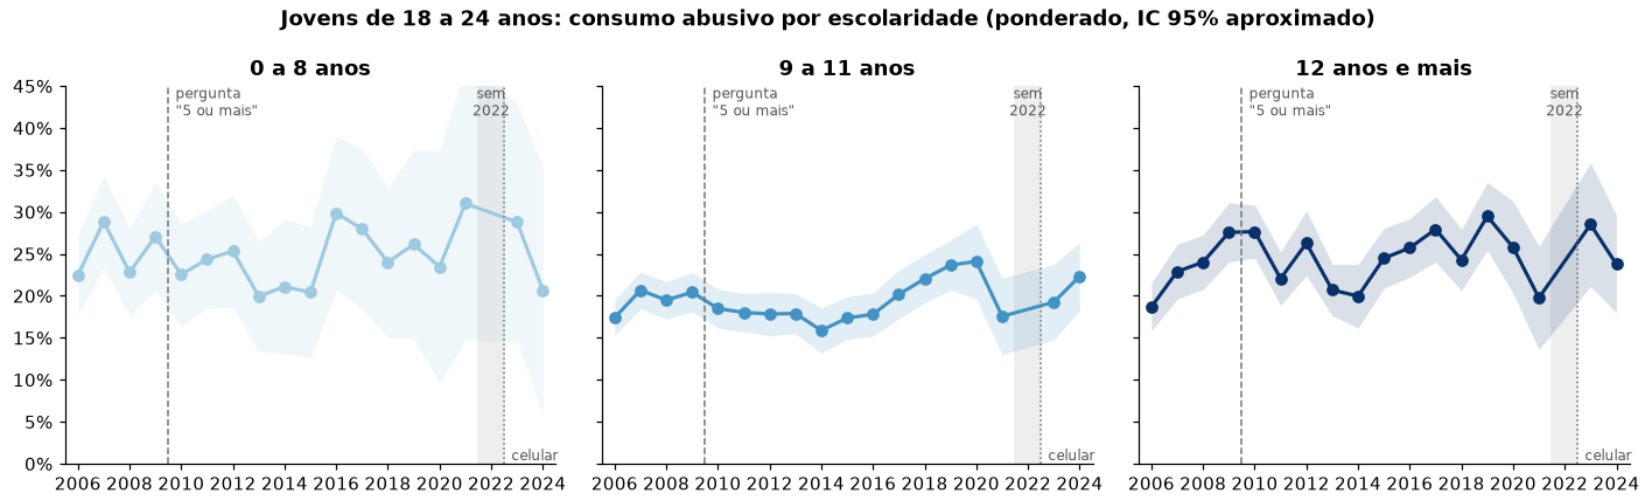
a edição não existe (D1)

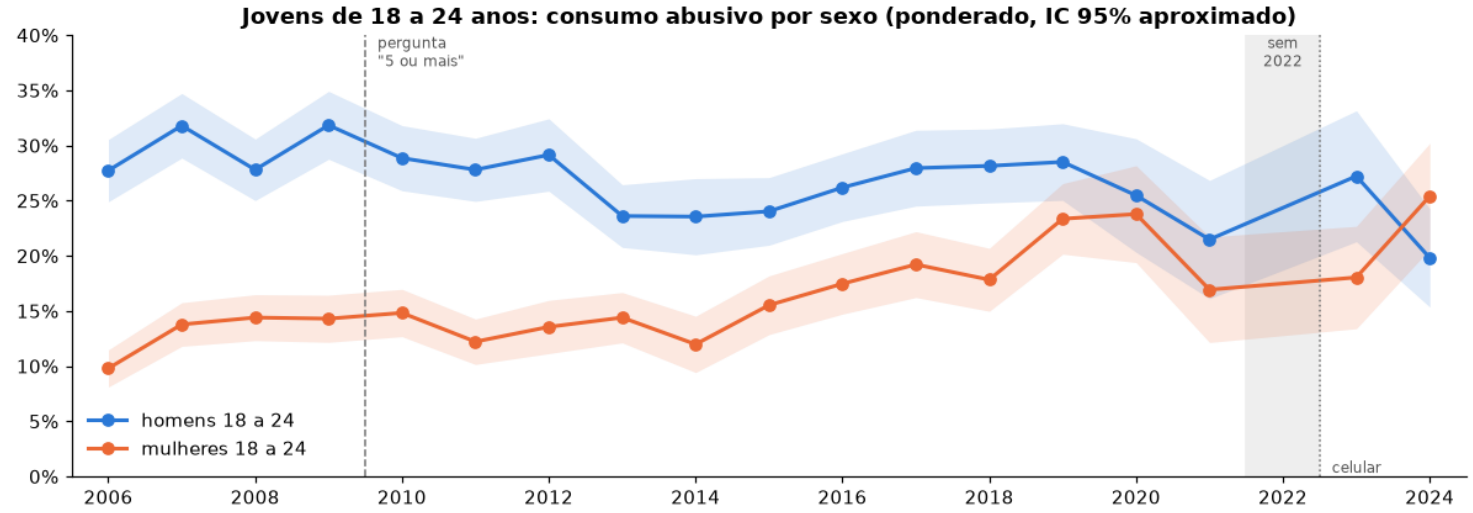
2023-24

entra o celular; em 2024 muda o filtro do bloco de álcool (D2, D13)

Na prévia (formulação v1), os jovens tinham 21,9% em 2010 e 22,7% em 2024. Mas as três rupturas estão justamente nas pontas da comparação: qualquer diferença entre 2010 e 2024 seria, em parte, efeito de método.

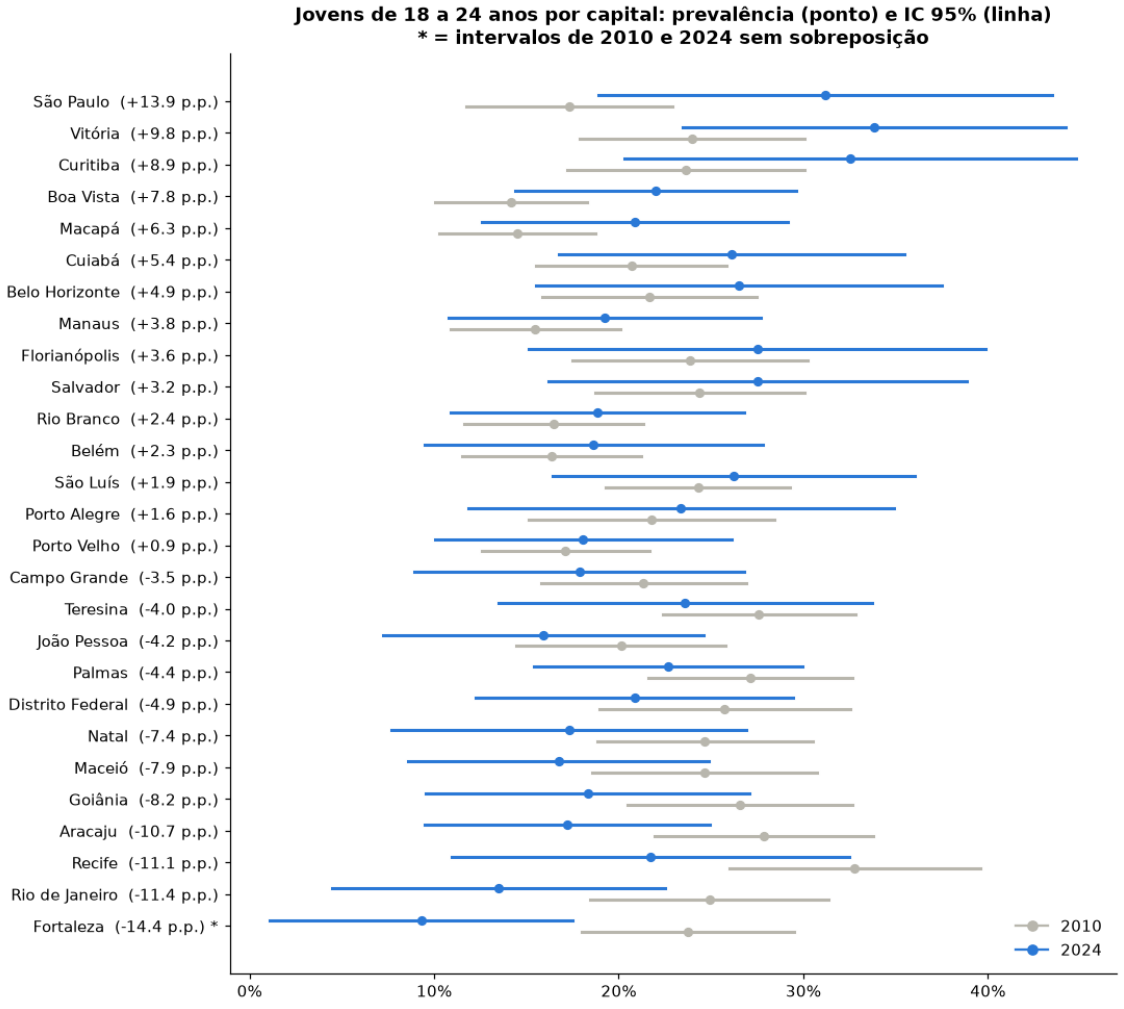
A prévia já apontava: o sinal estava no sexo





- Por escolaridade (acima): oscilação dentro da margem, sem tendência clara em nenhuma faixa
- **Por sexo (abaixo): a distância entre homens e mulheres jovens encolhe ao longo da série**
- Ainda comparando anos: serviu de pista, não de resposta

Por capital, a comparação de dois anos não tinha precisão



- Formulação v1: cada capital em 2010 (cinza) e em 2024 (azul)
- Diferenças de até ±14 p.p., mas com intervalos enormes
- Só Fortaleza sem sobreposição dos intervalos
- **Decisão D9: capitais com a margem de erro à vista e a região como apoio; e juntar as edições por geração para ganhar precisão**

Da pré-análise ao novo objetivo

Versão 1: comparar anos

- Jovens de 18-24 em 2010 x no ano mais recente
- Pontas da série afetadas por pergunta nova, celular e filtro novo
- Um ano isolado: poucos jovens e margem de ±3 p.p.

Versão 2: comparar gerações

- Millennials, zillennials e geração Z, sempre aos 18-24 anos
- Cada geração junta todas as edições em que foi observada
- P3 passa a acompanhar cada geração ao envelhecer

O problema, o decisor e a fonte continuaram os mesmos; mudou o desenho da comparação. A versão 1 fica preservada no Anexo A do README.

Decisões de tratamento

14 decisões, cada uma com alternativas descartadas e o motivo do autor

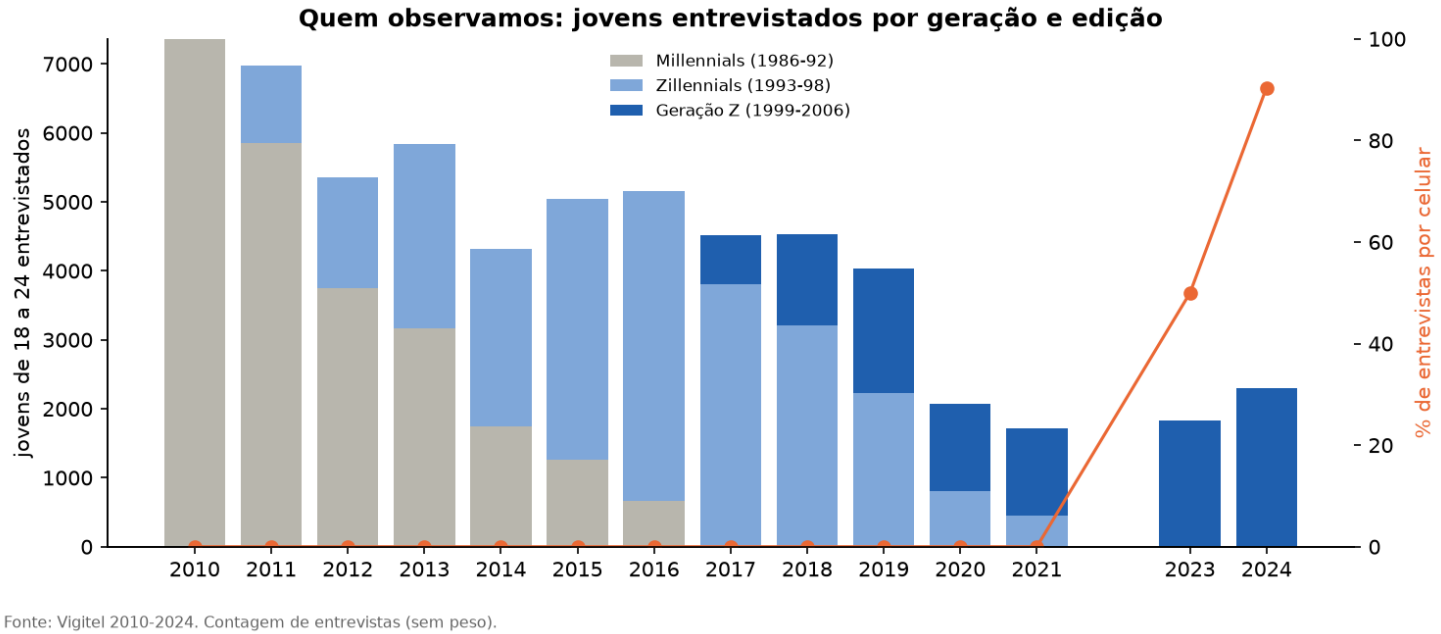
Decisões D1 a D7

	Problema	Decisão
D1	Não existe a edição de 2022	**Lacuna à vista, sem criar nenhum dado**
D2	2010 só fixo; 2024 com celular e filtro novo	**Comparar gerações na mesma idade, e não anos**
D3	Poucos jovens num ano isolado	**Juntar todas as edições de cada geração**
D4	Pesos em escalas diferentes entre anos	**Normalizar o peso para somar 1 por edição**
D5	Pergunta de doses mudou em 2010	**Usar só as edições de 2010 em diante**
D6	Pergunta “costuma beber” muda e some em 2024	**Decompor: quem bebe x exagero entre quem bebe**
D7	Escolaridade dos jovens mudou entre gerações	**Análise por faixa e média padronizada pela escolaridade**

Decisões D8 a D14

	Problema	Decisão
D8	Escolaridade estimada pelo Ministério (1%)	**Manter e testar sem esses casos**
D9	Poucos jovens por capital	**Capitais com margem de erro; região como apoio**
D10	Chave oficial falha e se repete	**Chave = edição + linha do arquivo original**
D11	Pandemia: amostra pela metade em 2020-21	**Manter e testar sem esses anos**
D12	Texto livre; região vazia em 2012	**Texto livre só na bronze (LGPD); região pela capital**
D13	Filtro novo do bloco de álcool em 2024	**Manter e testar sem 2024**
D14	Gerações observadas em idades diferentes	**Padronizar pela idade simples (18 a 24)**

D2: comparar gerações, e não anos



Fonte: Vigitel 2010-2024. Contagem de entrevistas (sem peso).

Millennials

nascidos em 1986-1992; observados aos 18-24 em 2010-2016, só fixo

Zillennials

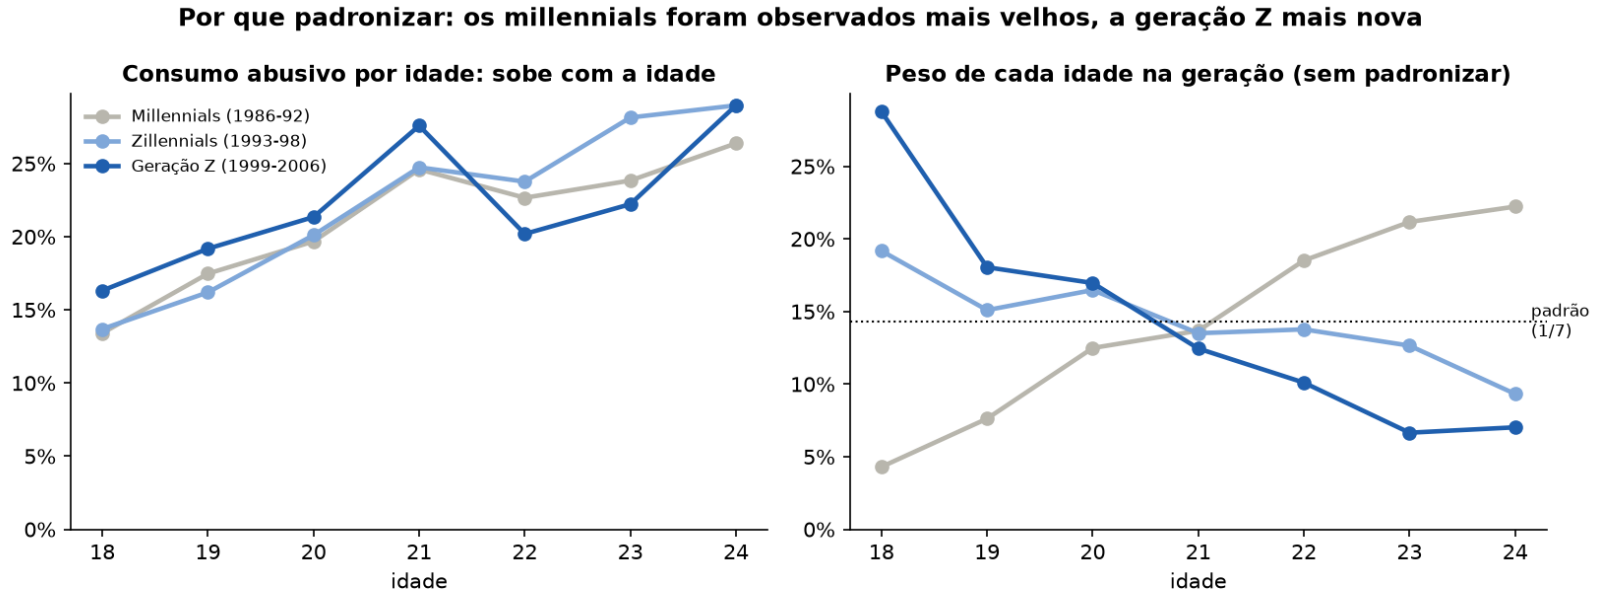
nascidos em 1993-1998; observados em 2011-2021, só fixo

Geração Z

nascidos em 1999-2006; observados em 2017-2024, 33% celular

- Geração = ano da pesquisa menos a idade. Sempre na mesma idade (18 a 24).
- Juntando vários anos por geração, a margem de erro cai para cerca de ±1 p.p.
- Millennials x zillennials: comparação toda por telefone fixo, sem mudança de método.

D14: na mesma idade, de fato



Fonte: Vigitel 2010-2024 (Ministério da Saúde). Prevalências ponderadas; IC 95% aproximado.

4% x 29%

do peso vem dos jovens de 18 anos: millennials x geração Z

- O consumo abusivo sobe com a idade: cerca de 14% aos 18 e 27% aos 24
- A janela 2010-2024 mostra os millennials mais velhos e a geração Z mais nova
- **Correção: média das 7 idades, com peso igual para cada uma, nas mesmas idades para todas as gerações**

Pipeline no Databricks

Arquitetura em camadas: raw, bronze, silver e gold, com qualidade e análise

Do arquivo oficial ao modelo estrela

Raw	Bronze	Silver	Gold	Consumo
Volume do Unity Catalog	bronze_vigitel	silver_vigitel	fato + 6 dimensões	qa_* e res_*
• ZIP oficial do Ministério • 87 MB, SHA-256 conferido • notebook 01	• cópia fiel do CSV • 833.217 linhas x 486 colunas • gravada em lotes de 20 mil	• 2010 em diante: 615.877 • 28 colunas, regras S1-S11 • sem texto livre (D12)	• modelo estrela • integridade referencial ok • notebook 03	• 16 regras de qualidade • P1 a P5 e veredito • notebooks 04 a 06

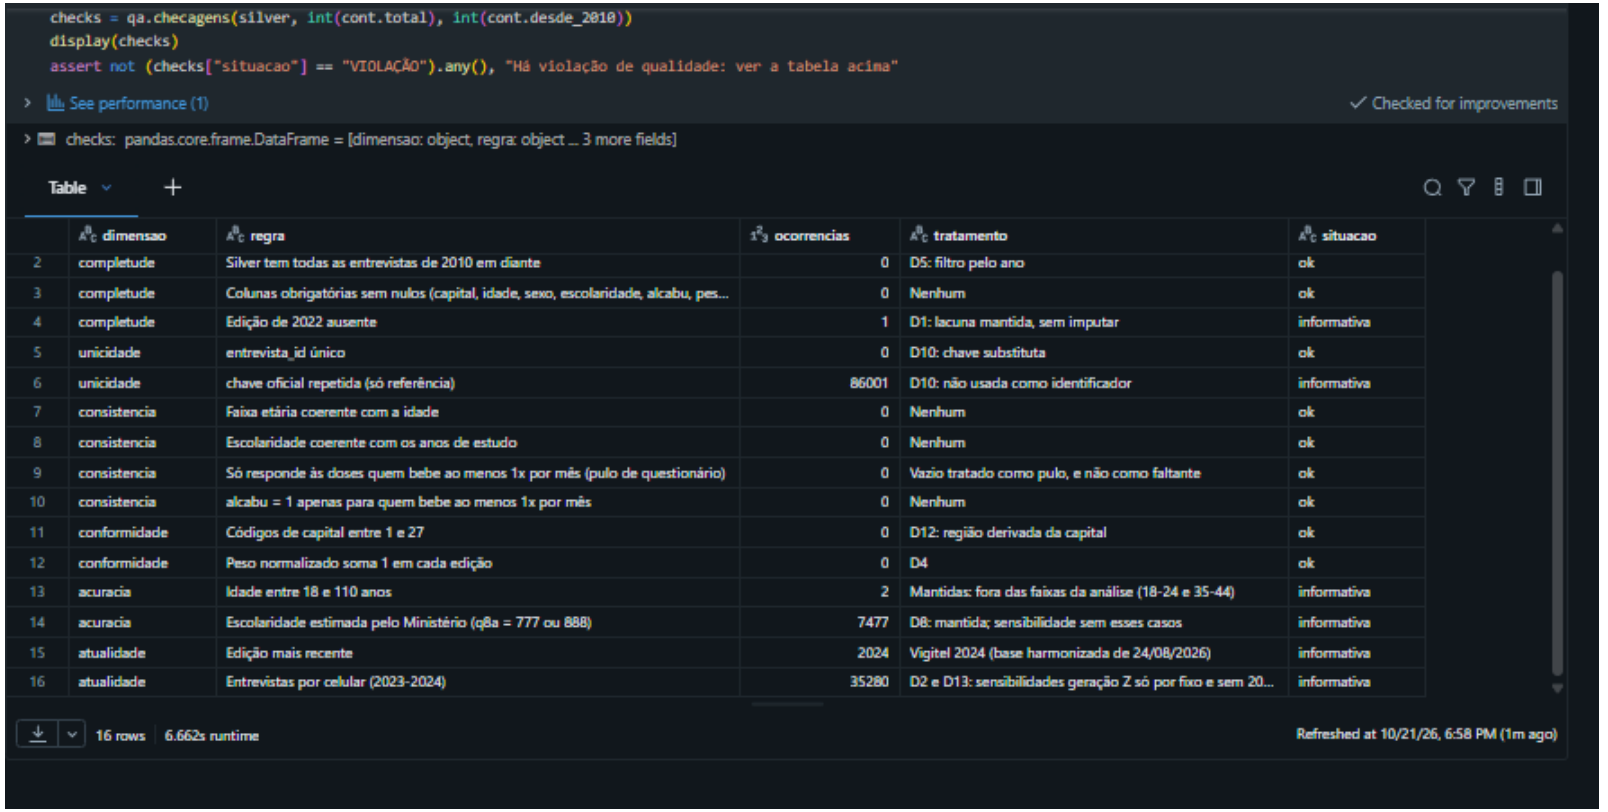
Site do Ministério → Volume → bronze → silver → gold → qualidade e respostas

As regras ficam em módulos Python (scripts/) chamados pelos notebooks, e podem ser testadas fora do cluster. Catálogo workspace, esquema genz_alcool, Delta Lake, computação serverless.

Modelo estrela: a entrevista é o fato



Qualidade: 16 regras em seis dimensões, nenhuma violação



```
checks = qa.checagens(silver, int(cont.total), int(cont.desde_2010))
display(checks)
assert not (checks["situacao"] == "VIOLAÇÃO").any(), "Há violação de qualidade: ver a tabela acima"
```

See performance (1) — Checked for improvements

checks: pandas.core.frame.DataFrame = [dimensao: object, regra: object ... 3 more fields]

Table

	dimensao	regra	ocorrencias	tratamento	situacao
2	completude	Silver tem todas as entrevistas de 2010 em diante	0	D5: filtro pelo ano	ok
3	completude	Colunas obrigatórias sem nulos (capital, idade, sexo, escolaridade, alcabu, pes...	0	Nenhum	ok
4	completude	Edição de 2022 ausente	1	D1: lacuna mantida, sem imputar	informativa
5	unicidade	entrevista_id único	0	D10: chave substituta	ok
6	unicidade	chave oficial repetida (só referência)	86001	D10: não usada como identificador	informativa
7	consistencia	Faixa etária coerente com a idade	0	Nenhum	ok
8	consistencia	Escolaridade coerente com os anos de estudo	0	Nenhum	ok
9	consistencia	Só responde às doses quem bebe ao menos 1x por mês (pulo de questionário)	0	Vazio tratado como pulo, e não como faltante	ok
10	consistencia	alcabu = 1 apenas para quem bebe ao menos 1x por mês	0	Nenhum	ok
11	conformidade	Códigos de capital entre 1 e 27	0	D12: região derivada da capital	ok
12	conformidade	Peso normalizado soma 1 em cada edição	0	D4	ok
13	acuracia	Idade entre 18 e 110 anos	2	Mantidas: fora das faixas da análise (18-24 e 35-44)	informativa
14	acuracia	Escolaridade estimada pelo Ministério (q8a = 777 ou 888)	7477	D8: mantida; sensibilidade sem esses casos	informativa
15	atualidade	Edição mais recente	2024	Vigitel 2024 (base harmonizada de 24/08/2026)	informativa
16	atualidade	Entrevistas por celular (2023-2024)	35280	D2 e D13: sensibilidades geração Z só por fixo e sem 20...	informativa

16 rows | 6.662s runtime — Refreshed at 10/21/26, 6:58 PM (1m ago)

Captura do notebook 04 no Databricks (21/10/2026): tabela qa_checagens

- Completude, unicidade, consistência, conformidade, acurácia e atualidade
- Pulo das doses conferido em 100% dos casos
- Peso normalizado soma 1 em cada edição
- **Informativas, não erros: 7.477 escolaridades estimadas, 35.280 entrevistas por celular**
- Perfil dos 28 atributos da silver: nulos, distintos, mínimo e máximo

Evidência: coleta e bronze persistidas no Databricks



Notebook 01: o ZIP no Volume, com tamanho e SHA-256 conferidos



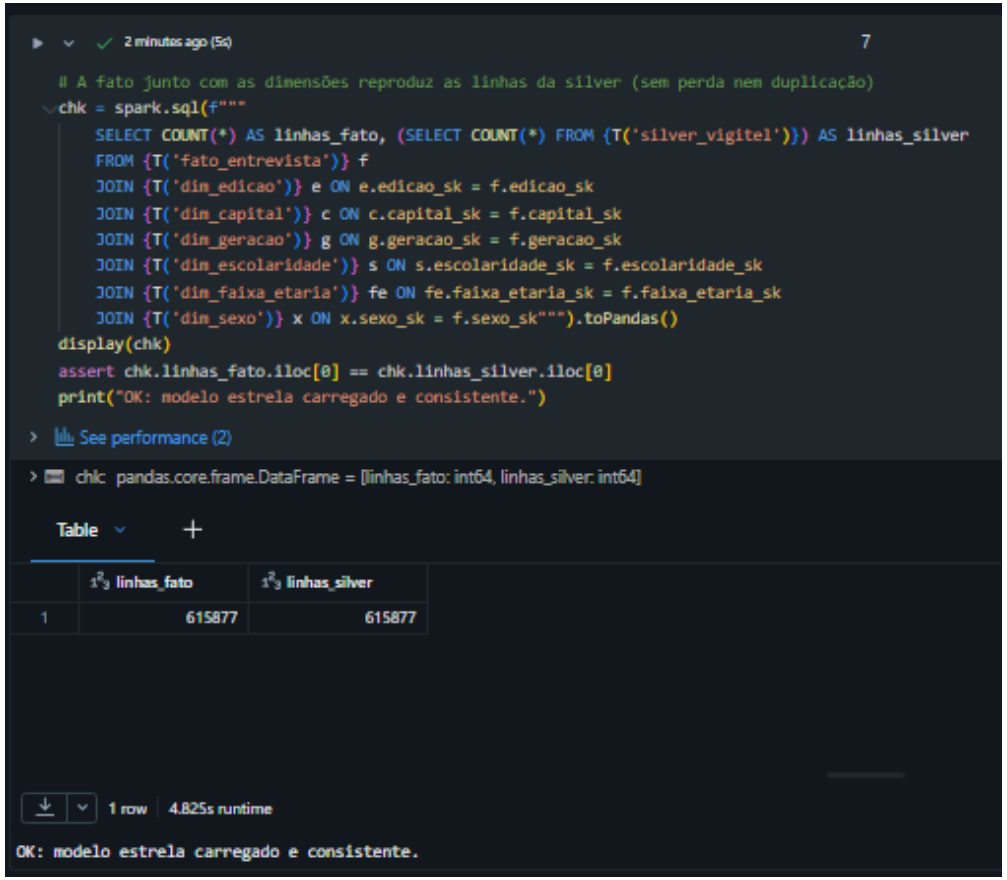
Notebook 01: bronze com 833.217 linhas, as mesmas do CSV

Evidência: silver e gold consistentes



Notebook 02: jovens de cada geração na silver e as edições em que aparecem

- Millennials: 23.805 jovens; zillennials: 26.745; geração Z: 10.485
- 26 tabelas Delta persistidas no esquema genz_alcool

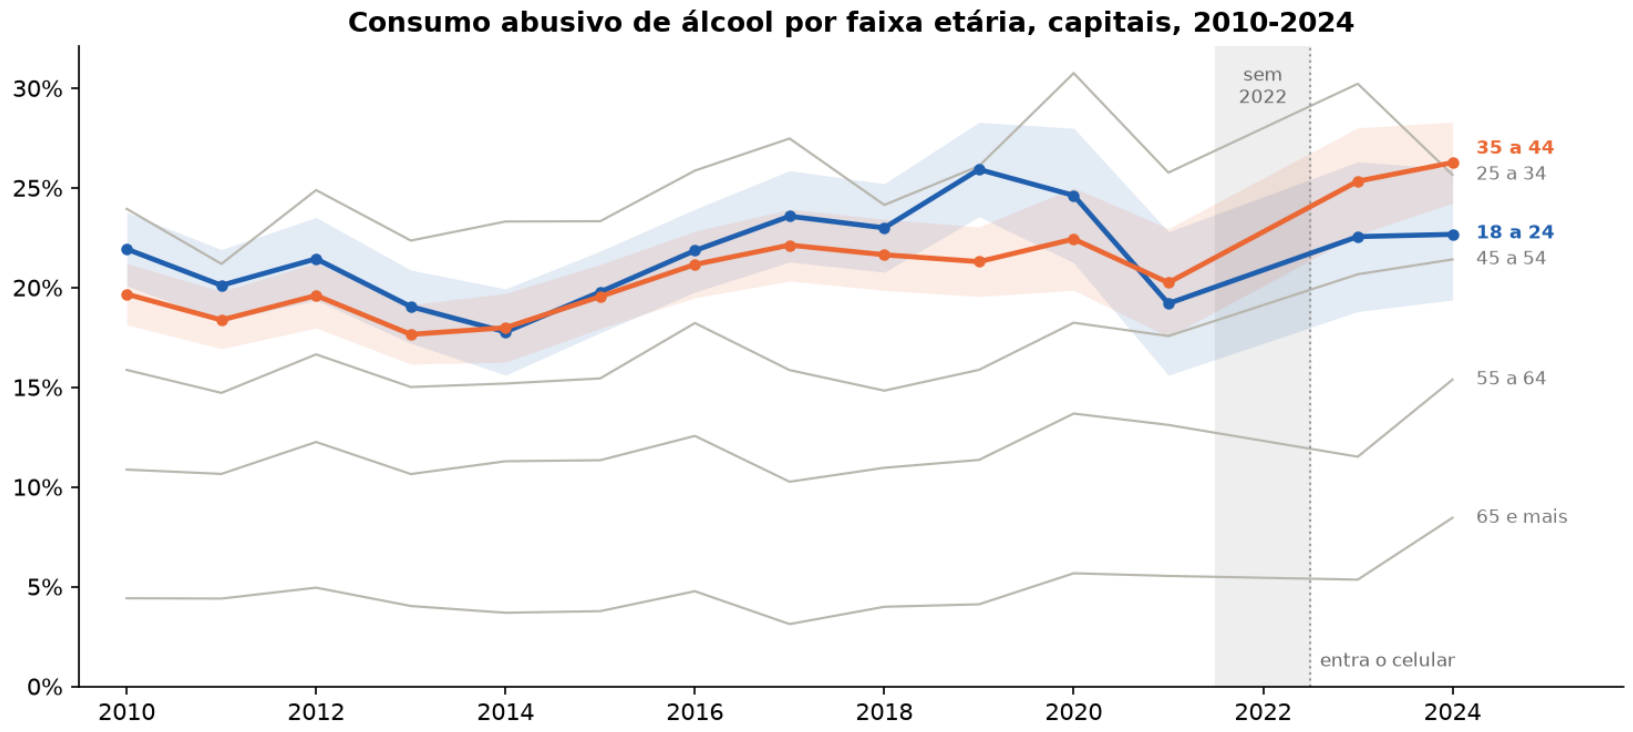


Notebook 03: a fato com as 6 dimensões reproduz as 615.877 linhas da silver

Resultados

P1 a P5, robustez e veredito

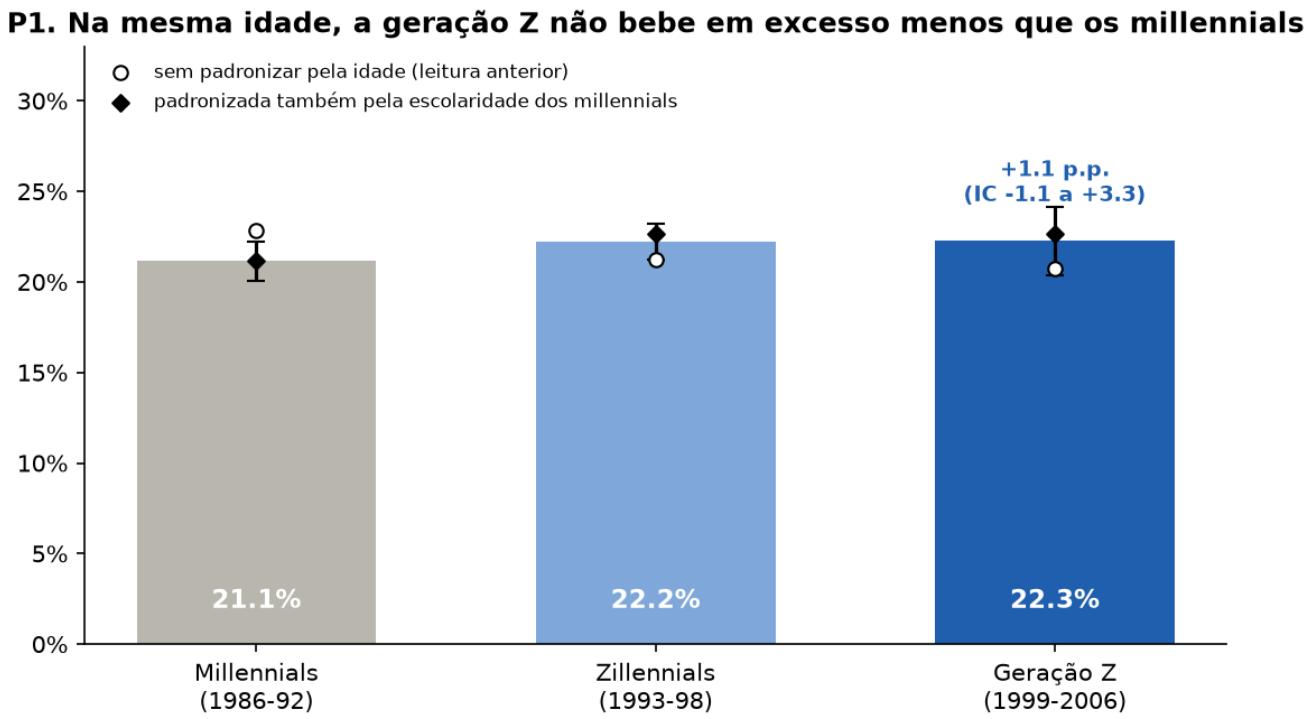
A série histórica não mostra queda entre os jovens



Fonte: Vigitel 2010-2024 (Ministério da Saúde). Prevalências ponderadas; IC 95% aproximado.

- Jovens (azul): 21,9% em 2010 e 22,7% em 2024
- Adultos de 35-44 (laranja) sobem mais no período
- Faixa cinza: 2022 não existe; linha pontilhada: entra o celular
- **Ponto de partida, não resposta: a resposta vem por geração**

P1. Na mesma idade, a geração Z não bebe menos



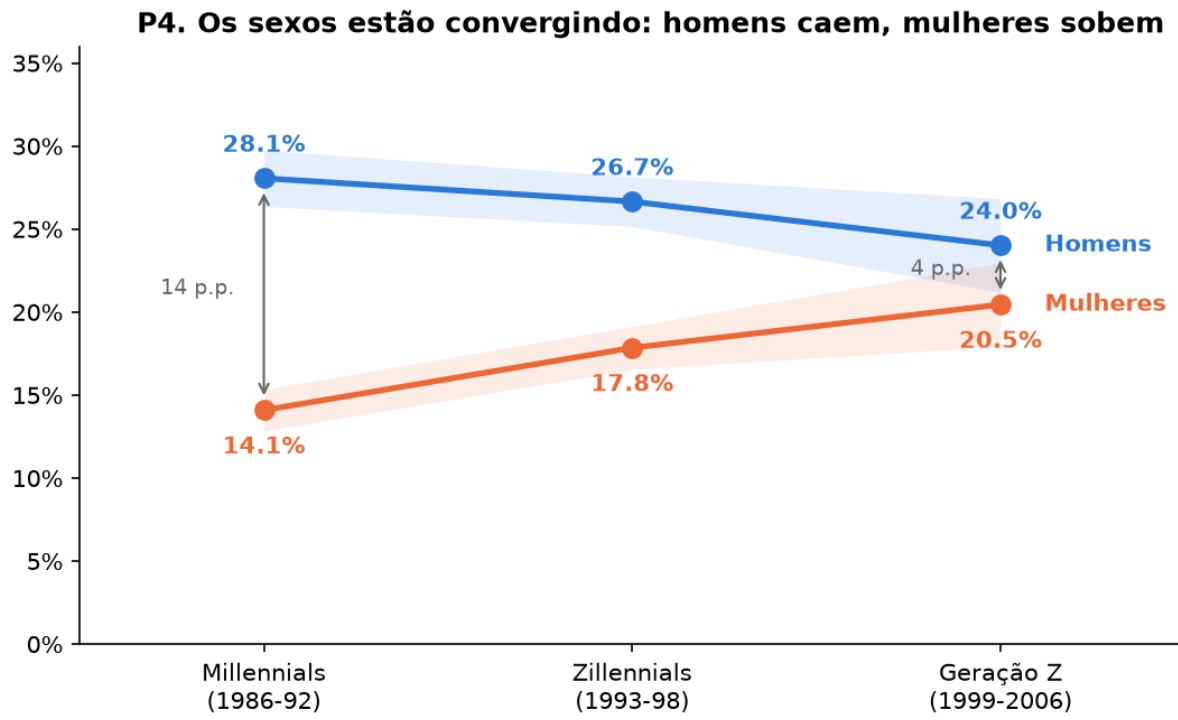
Fonte: Vigitel 2010-2024 (Ministério da Saúde). Prevalências ponderadas e padronizadas pela idade (18 a 24, peso igual por ano de idade); IC 95% aproximado.

+1,1 p.p.

geração Z em relação aos millennials, aos 18-24, padronizada pela idade (IC 95%: −1,1 a +3,3)

- 21,1% → 22,2% → 22,3%; nenhuma diferença significativa
- Sem padronizar (círculo), aparecia −2,1 p.p.: a queda vinha da idade
- Padronizada também pela escolaridade (losango): quase igual

P4. Sem separar os sexos, nada muda; separando, tudo muda



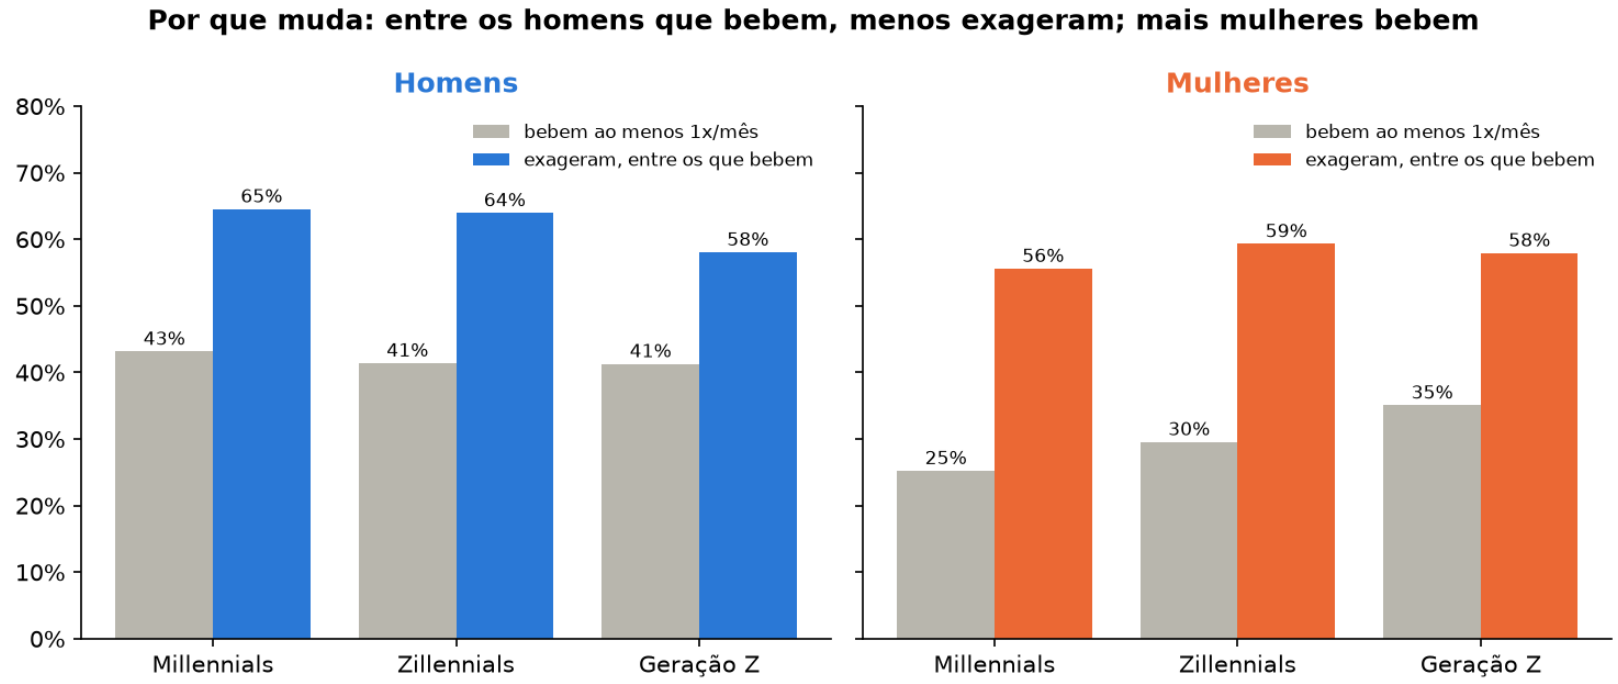
Fonte: Vigitel 2010-2024 (Ministério da Saúde). Prevalências ponderadas e padronizadas pela idade (18 a 24, peso igual por ano de idade); IC 95% aproximado.

14 → 3,5

p.p. de distância entre homens e mulheres, de millennials para geração Z

- **Homens: −4,0 p.p. (28,1% → 24,0%)**
- **Mulheres: +6,4 p.p. (14,1% → 20,5%)**
- Os dois movimentos se cancelam no total

Por que muda: homens moderam, mais mulheres bebem



Fonte: Vigitel 2010-2024 (Ministério da Saúde). Prevalências ponderadas e padronizadas pela idade (18 a 24, peso igual por ano de idade); IC 95% aproximado.

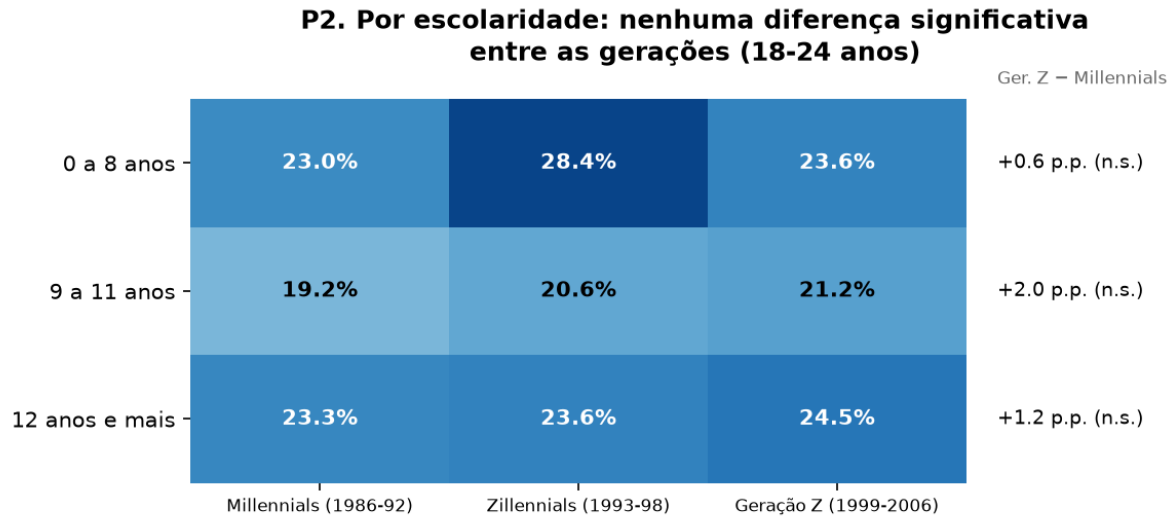
Homens

Quase o mesmo tanto bebe (43% → 41%); quem bebe exagera menos (65% → 58%)

Mulheres

Mais bebem (25% → 35%); o exagero entre quem bebe fica estável (56% → 58%)

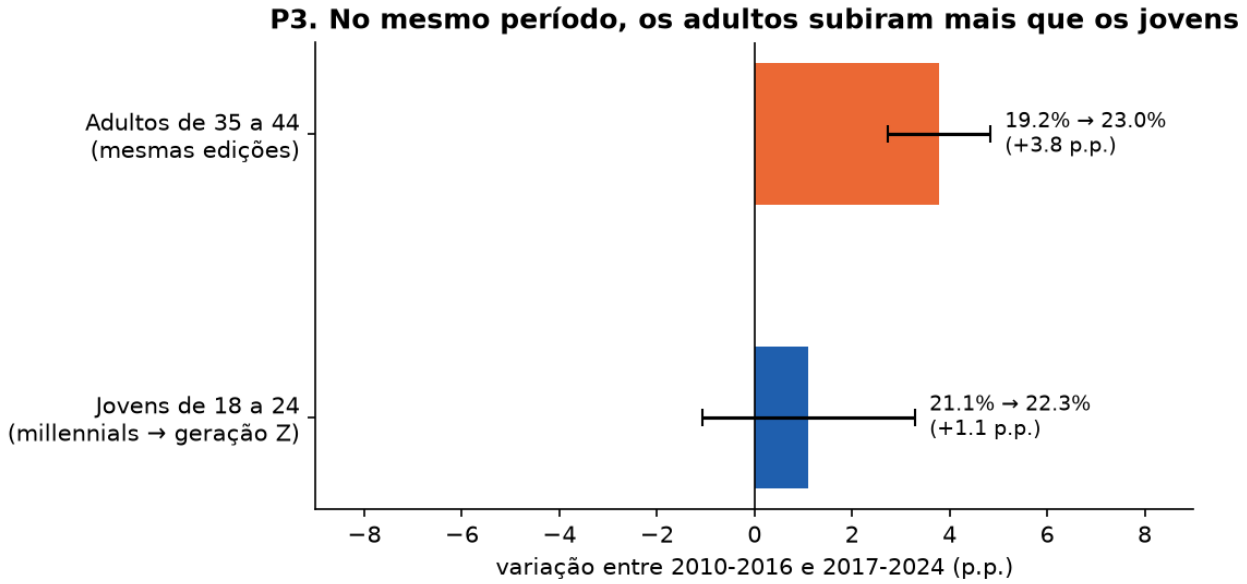
P2. Por escolaridade, nenhuma diferença significativa



Fonte: Vigitel 2010-2024 (Ministério da Saúde). Prevalências ponderadas e padronizadas pela idade (18 a 24, peso igual por ano de idade); IC 95% aproximado. n.s. = intervalo inclui o zero.

- De +0,6 a +2,0 p.p. nas três faixas, todas dentro da margem de erro
- Sem os casos de escolaridade estimada (D8): mesmo resultado
- **Não há queda concentrada em nenhuma classe, nem queda ampla**

P3. Os jovens subiram menos que a época



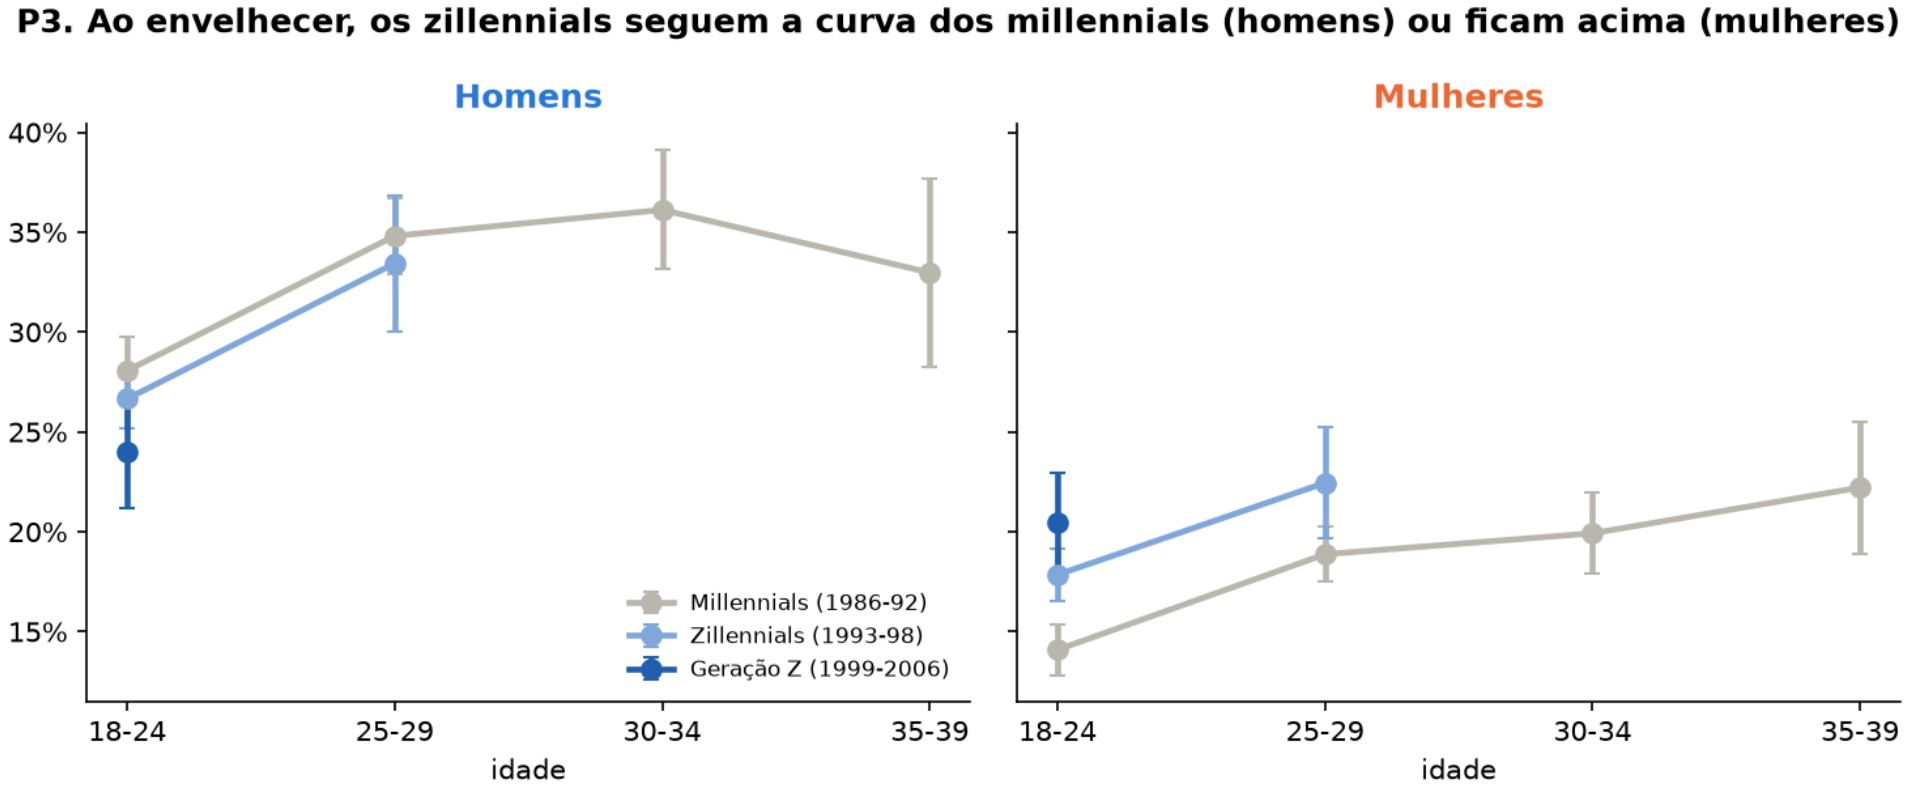
Fonte: Vigitel 2010-2024 (Ministério da Saúde). Prevalências ponderadas e padronizadas pela idade (18 a 24, peso igual por ano de idade); IC 95% aproximado.

−2,7 p.p.

jovens (+1,1) em relação aos adultos de 35-44 (+3,8) no mesmo período (IC 95%: −5,1 a −0,3)

Os jovens não beberam menos, mas cresceram menos que a tendência geral: um efeito relativo de geração, e não uma queda.

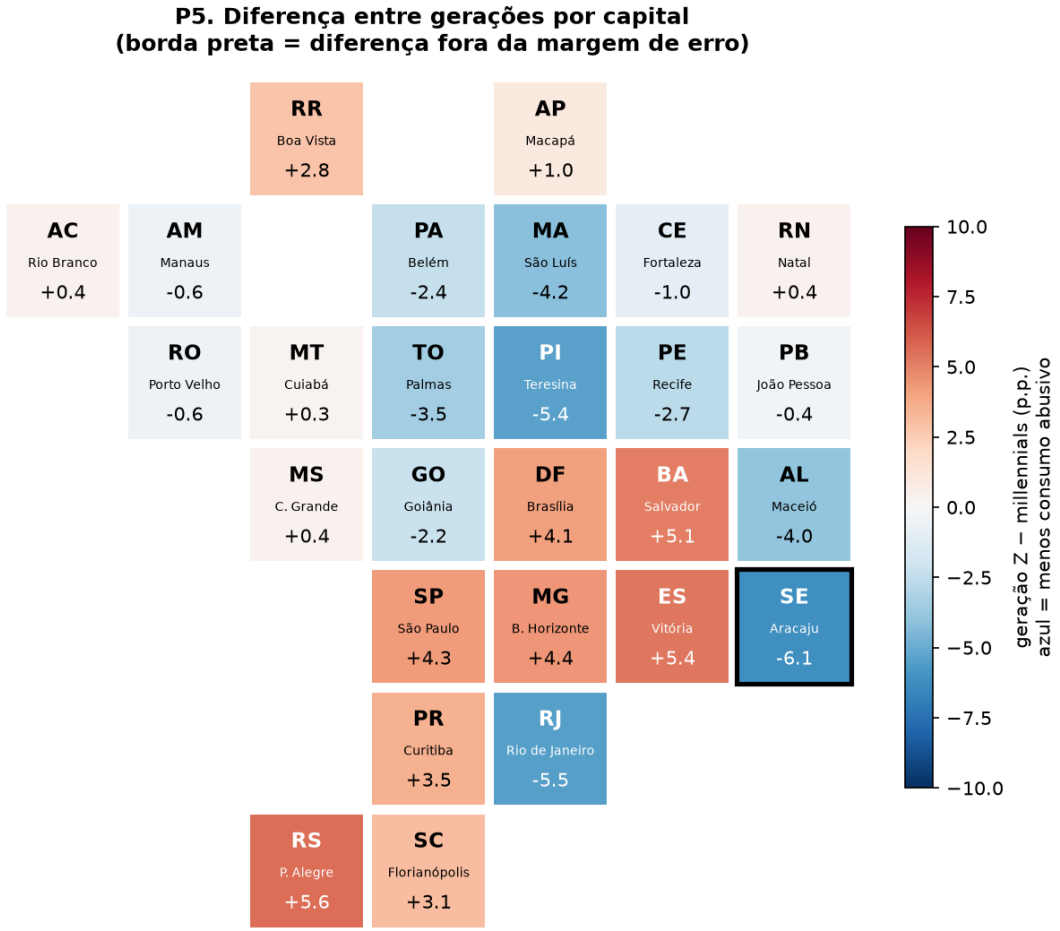
P3. Ao envelhecer, as curvas ficam paralelas



Fonte: Vigitel 2010-2024 (Ministério da Saúde). Prevalências ponderadas e padronizadas pela idade (dentro de cada faixa, peso igual por ano de idade); IC 95% aproximado. Grupos com 300 ou mais entrevistas.

Homens zillennials: 1,4 p.p. abaixo dos millennials aos 18-24 (26,7% x 28,1%) e aos 25-29 (33,4% x 34,8%): curvas paralelas, sem sinal de adiamento. Mulheres zillennials acima nas duas faixas; a geração Z ainda é jovem demais.

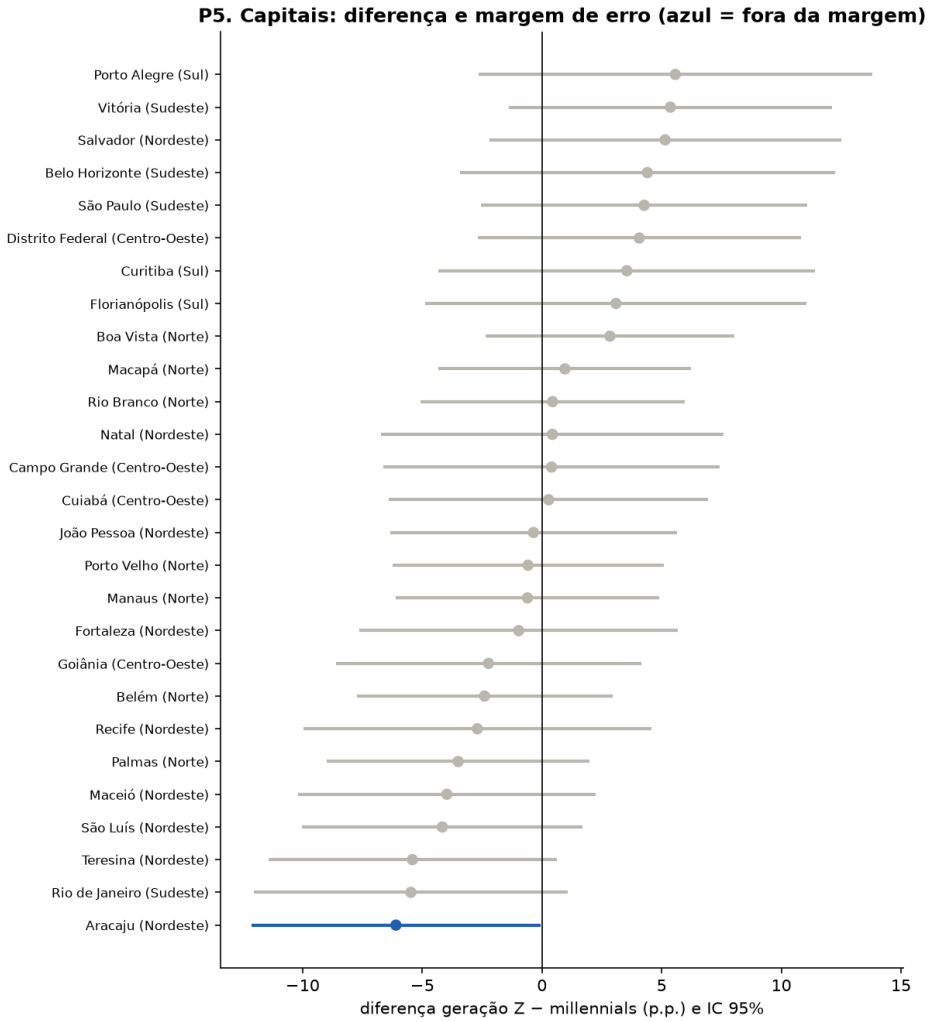
P5. Nenhuma região muda de forma clara



- Só Aracaju fora da margem de erro (−6,1 p.p.); com 27 capitais, uma é esperada só pelo acaso
- Nenhuma região significativa (de −0,5 p.p. no Norte a +4,5 no Sul)
- Dentro da margem: a maioria do Nordeste cai; Sul e Sudeste (exceto o Rio) sobem
- **Capital inconclusiva: usar a região como apoio (D9)**

Fonte: Vigitel 2010-2024 (Ministério da Saúde). Prevalências ponderadas e padronizadas pela idade em três faixas (18-19, 20-21, 22-24); IC 95% aproximado.

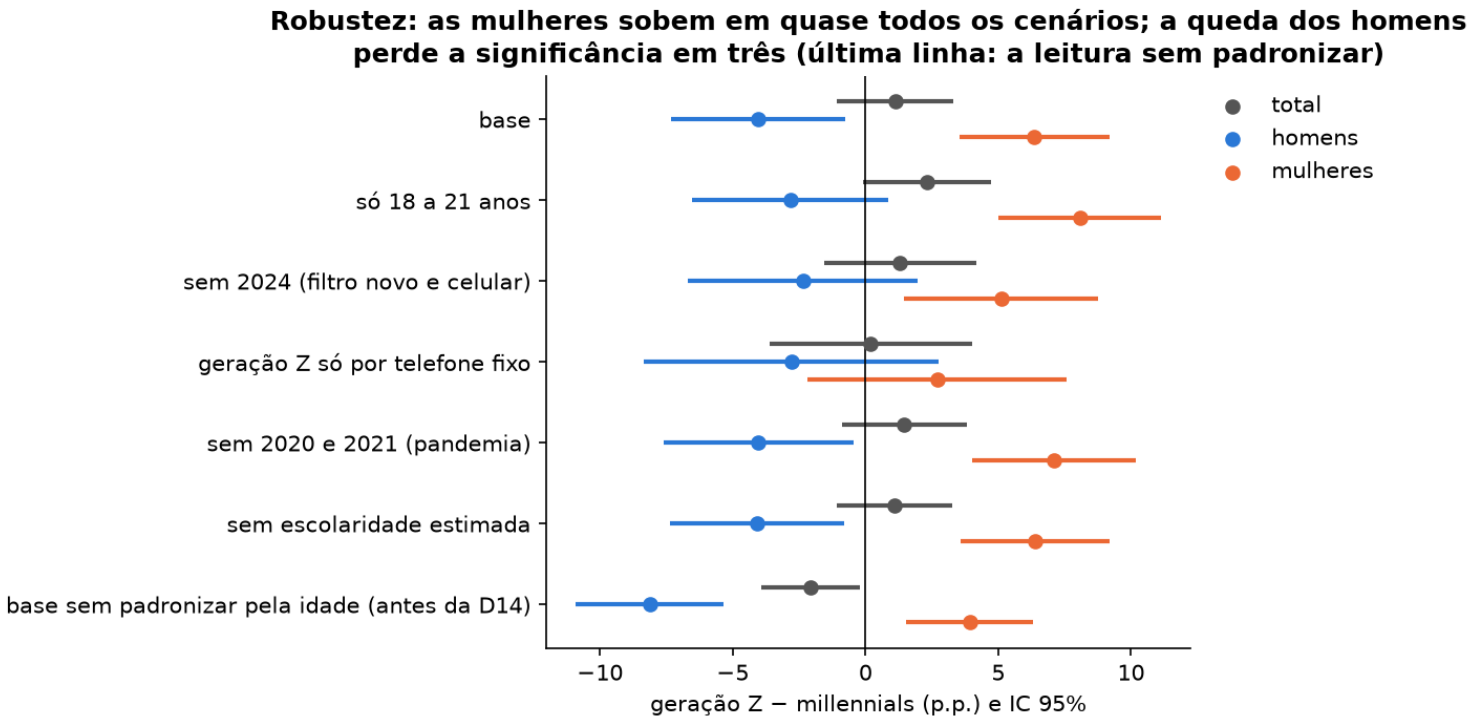
P5. Diferença e margem de erro por capital



Fonte: Vigitel 2010-2024 (Ministério da Saúde). Prevalências ponderadas e padronizadas pela idade em três faixas (18-19, 20-21, 22-24); IC 95% aproximado.

- Diferença geração Z − millennials aos 18-24 anos, por capital
- Azul: o intervalo de 95% não inclui o zero
- Cerca de 390 jovens da geração Z por capital: margem de ±5 a 6 p.p.
- **Com essa precisão, os dados não sustentam uma priorização regional de lançamento**

Robustez: alta feminina firme, queda masculina frágil



Fonte: Vigitel 2010-2024 (Ministério da Saúde). Prevalências ponderadas e padronizadas pela idade (idades comuns às gerações, peso igual por ano de idade); IC 95% aproximado.

- Seis cenários e, na última linha, a leitura sem padronizar
- **Mulheres: +5,1 a +8,1 p.p., significativa em cinco dos seis**
- **Homens: −2,4 a −4,1 p.p.; perde a significância aos 18-21, sem 2024 e só por fixo**
- Sem padronizar, a queda total aparecia: era efeito da idade

Veredito: hipótese refutada no que tem de central

✗ **(a) Na mesma idade, a prevalência da geração Z é menor que a dos millennials?**

Não: +1,1 p.p. (−1,1 a +3,3)

✗ **(b) A queda ocorre nos dois sexos e nas três faixas de escolaridade?**

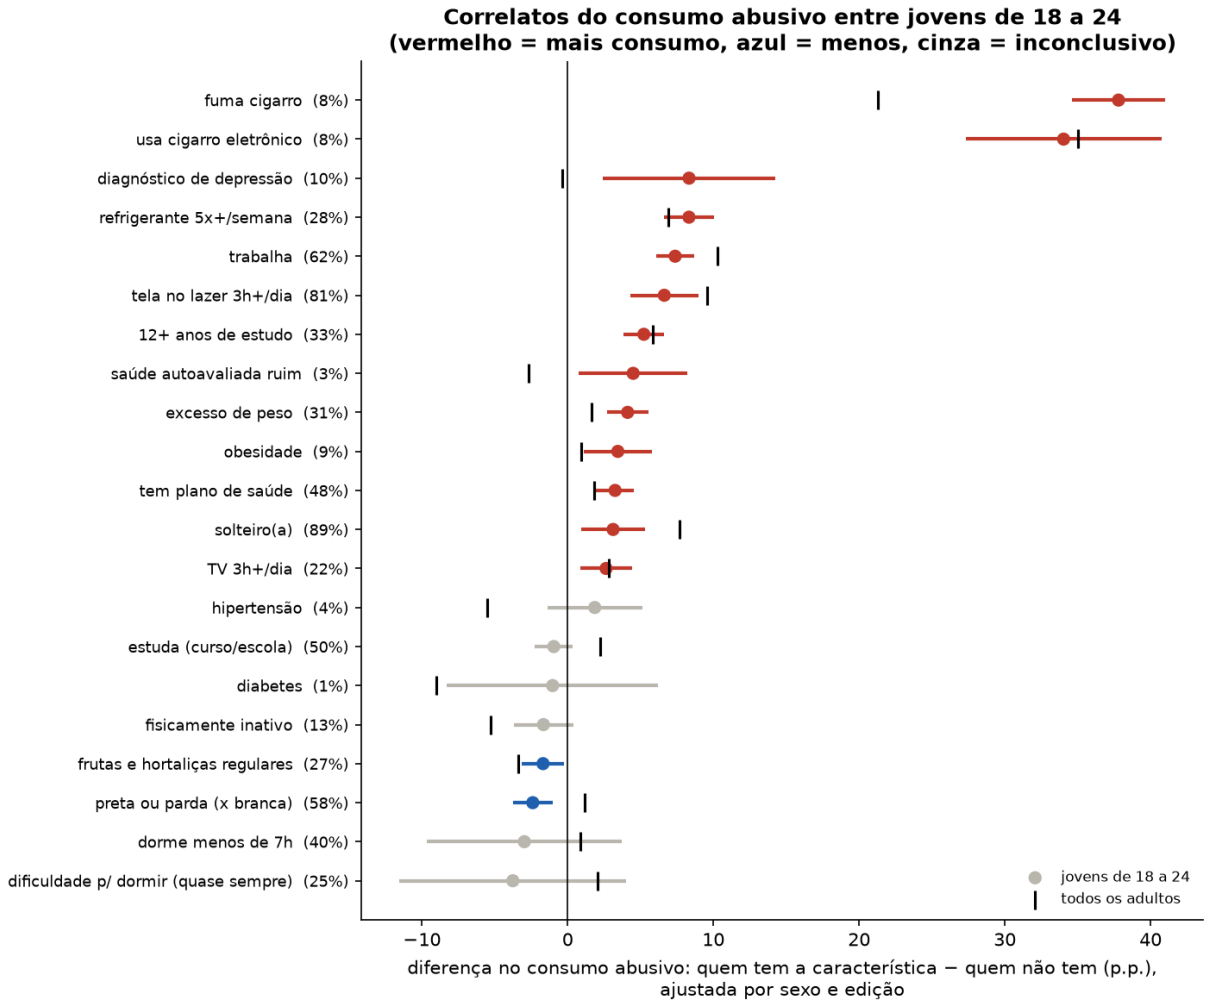
Não: homens −4,0; mulheres +6,4; nenhuma faixa de escolaridade cai

✓ **(c) Os jovens mudam de forma diferente da tendência geral (adultos de 35-44)?**

Sim: jovens +1,1 contra adultos +3,8 (diferença de −2,7; IC −5,1 a −0,3)

Na mesma idade, a geração Z não bebe menos: os sexos é que convergem.

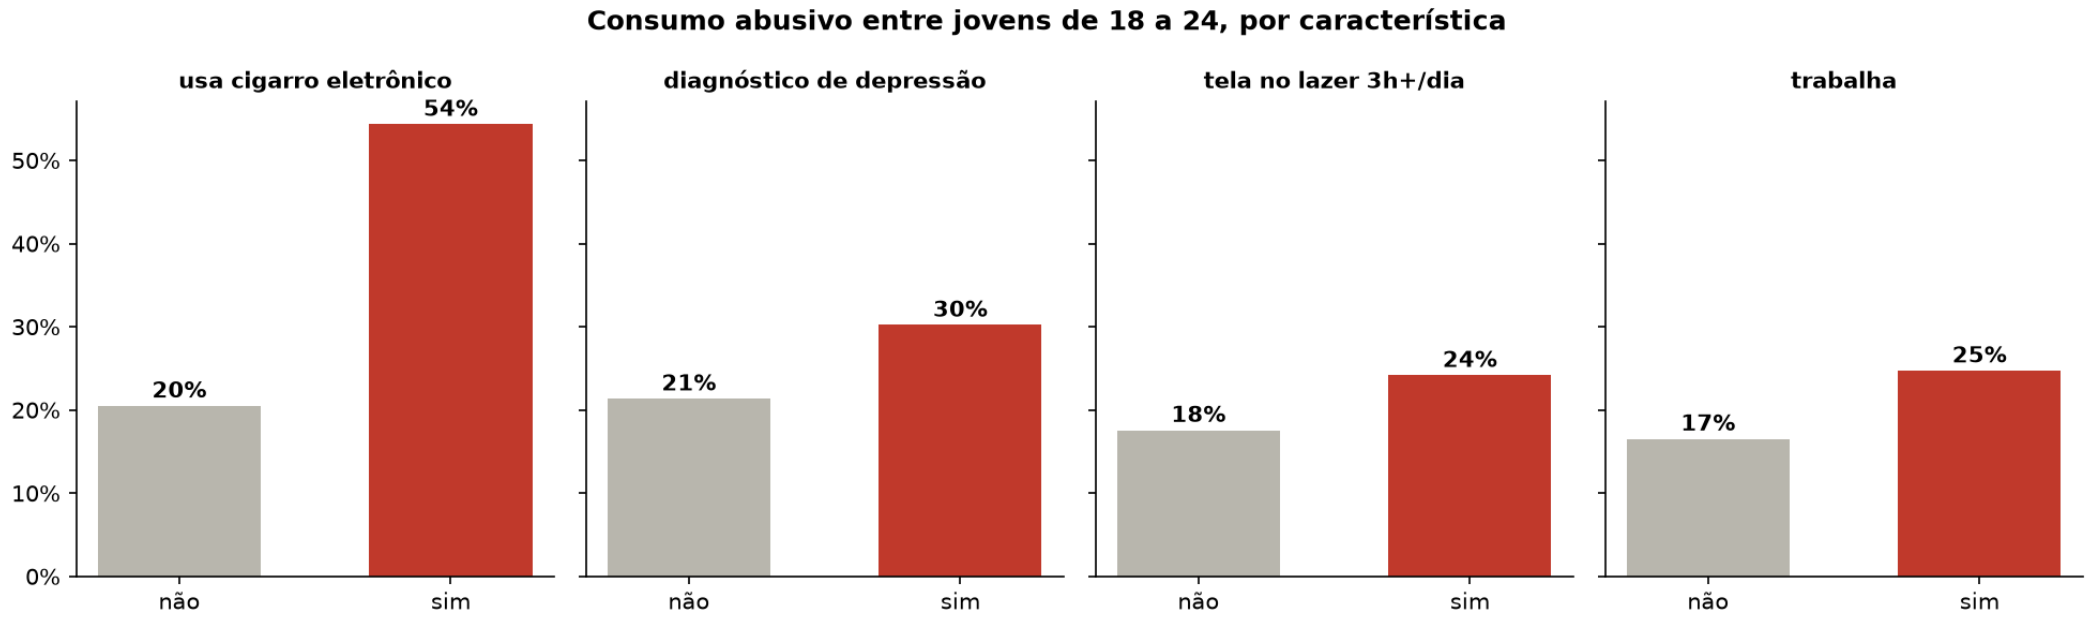
O que anda junto com o consumo abusivo entre jovens



- 21 características do Vigitel, ajustadas por sexo e edição
- **Cigarro e vape: +38 e +34 p.p.**
- **Depressão: +8 p.p. só entre os jovens (nos adultos, zero)**
- **Tela 3h+/dia: +7 p.p. (o celular não substitui o bar)**
- Hipertensão, diabetes, inatividade: sem associação, como esperado
- *Associação não é causa; com 21 testes, ~1 pode ser acaso*

Fonte: Vigitel 2010-2024 (Ministério da Saúde). Prevalências ponderadas; IC 95% aproximado. Entre parênteses, % de jovens com a característica. Associação não é causa.

Quatro destaques, em números brutos



Fonte: Vigitel (edições em que cada pergunta existe). Prevalências ponderadas, sem ajuste; o ajuste por sexo e edição está na f13.

Em cada painel: "não" = jovens sem a característica; "sim" = com a característica. A barra é a % do grupo com consumo abusivo.

54%

dos jovens que usam cigarro eletrônico bebem em excesso (20% de quem não usa)

24%

de quem passa 3h+ por dia em telas no lazer (18% de quem passa menos)

Discussão

O que os números dizem sobre o problema de negócio

Duas lições de método

−2,1 → +1,1

p.p., geração Z − millennials: sem padronizar e padronizando pela idade

−4,0 e +6,4

p.p., homens e mulheres: dois movimentos que se cancelam no total

Padronizar públicos diferentes

- Mesma base, mesmo indicador, vereditos opostos
- A geração Z parecia beber menos só por ter sido entrevistada mais nova

O agregado esconde

- Total: sem diferença entre as gerações
- Homens: queda leve e frágil; mulheres: alta robusta

Antes de aceitar uma manchete como “a geração Z bebe menos”, é preciso perguntar: comparada na mesma idade? e dentro de quais grupos?

O que isso significa para as duas decisões

Decisão 1: nicho ou massa

Nenhuma faixa de escolaridade bebe menos. A premissa das duas opções (uma queda do consumo) não aparece. A moderação dos homens que bebem aponta mais para baixo teor do que para a substituição do álcool, mas é um sinal frágil.

Decisão 2: estrutural ou fase

Nos homens millennials e zillennials, as curvas são paralelas ao envelhecer: a mudança acompanha a geração, sem adiamento. A geração Z ainda não pode ser acompanhada; a resposta fica para as próximas edições.

Saúde pública

A alta robusta entre as jovens indica que a prevenção ao consumo abusivo não pode mais tomar o público masculino como o único foco.

Recomendação: esperar mais dados antes de investir pesado

A manchete não se confirma no Brasil, e o custo de agir com base nela é exatamente o erro que o projeto queria evitar.

1

Confirmar com outras fontes

Além de pesquisa e autorrelato: dados de vendas e de volume (varejo, POF do IBGE, dados da própria empresa).

2

Medir quantidade, não só exagero

Investigar a relação entre consumo abusivo e quantidade consumida: o mercado é definido pelo volume.

3

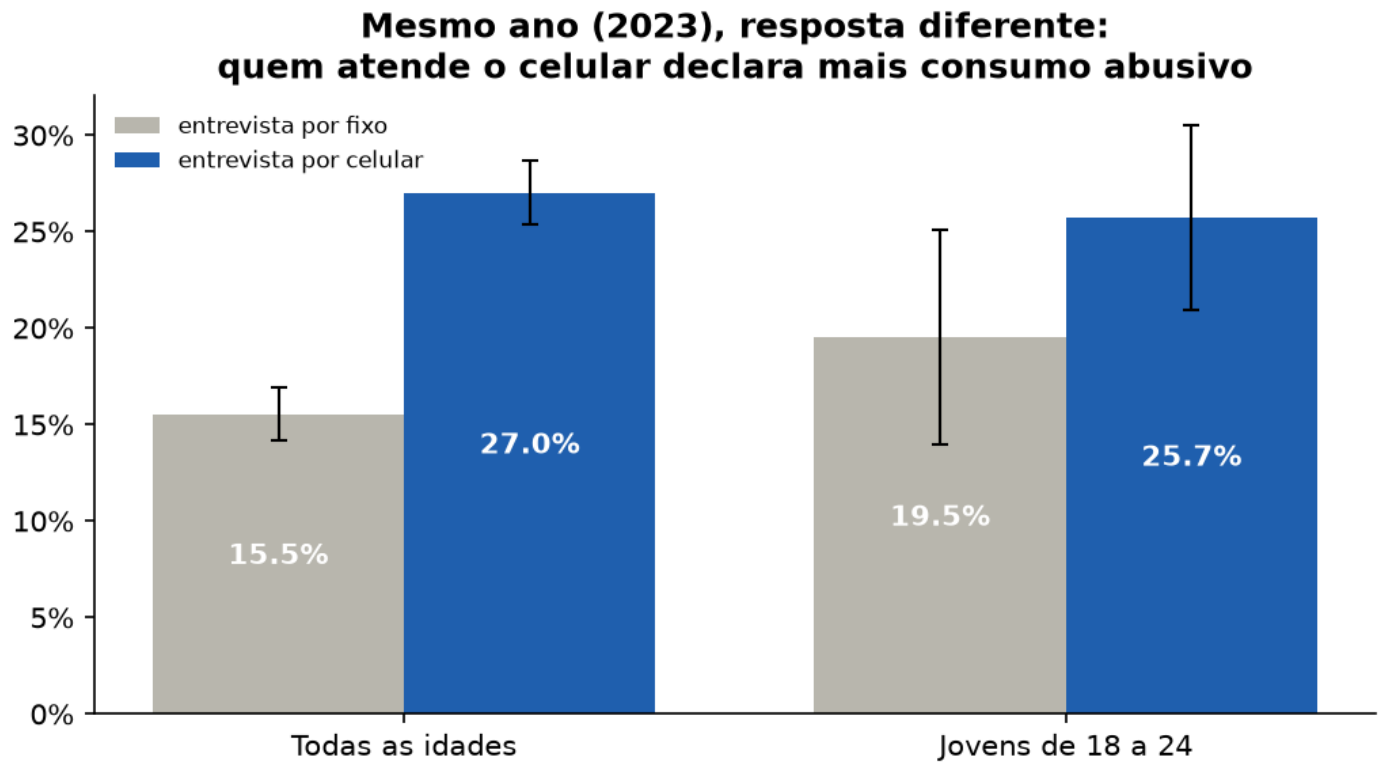
Olhar para as jovens

A mudança mais robusta da série: oportunidade de mercado e alerta de saúde pública.

Limitações

Até onde os números permitem ir

O modo de coleta muda a resposta



Fonte: Vigitel 2010-2024 (Ministério da Saúde). Prevalências ponderadas; IC 95% aproximado.

+11,5 p.p.

diferença entre celular e fixo no mesmo ano (2023), todas as idades

- Quem tem fixo é outro público (mais velho, casa estruturada)
- No celular a pessoa responde sozinha, sem a família por perto
- **Só a geração Z tem celular: a sensibilidade só por fixo reduz a alta feminina para +2,7 (n.s.)**

Limitações dos dados e do desenho

Alcance

- Só capitais e Distrito Federal
- Recortes de geração do Pew, pensados para os EUA
- Não testa a manchete fora do Brasil

Medida

- Autorrelato por telefone (desejabilidade social)
- Prevalência, não volume nem tipo de bebida
- Escolaridade no lugar de renda

Coleta e amostra

- Celular só na geração Z
- Quem não responde não aparece (possível MNAR)
- Sem 2022; pandemia em 2020-2021

Desenho

- Idade, geração e época não se separam por completo
- Poucos casos por capital: n.s. = “não deu para afirmar”
- Muitos testes (21 correlatos, 27 capitais)

Autoavaliação: o que foi respondido

P1 — **Respondida**

na mesma idade, sem queda; correta só depois da D14

P2 — **Respondida, com poder limitado**

nenhuma faixa cai; vale para escolaridade, não renda

P3 — **Respondida em parte**

geração Z ainda não chegou aos 25-29 anos

P4 — **Respondida**

convergência dos sexos: alta feminina robusta

P5 — **Pouco conclusiva**

uma capital fora da margem, compatível com acaso

Dificuldades

- Limites do Free Edition: a bronze precisou ser gravada em lotes de 20 mil linhas
- Tempo de execução: só a bronze levou cerca de 5 minutos; cada ajuste exigia rodar a cadeia de novo
- Refazer resultados, figuras e apresentação depois da D14

O que eu faria diferente e os próximos passos

Se recomeçasse

- Definir a comparação por geração e na mesma idade desde o objetivo
- Levantar as mudanças de método da pesquisa no primeiro dia
- Levar o pipeline ao Databricks mais cedo
- Fixar antes quais testes seriam feitos

Para uso contínuo

- Job do Databricks a cada nova edição, com a qualidade bloqueando a carga
- Painel para o decisor, com a margem de erro sempre visível
- Juntar PNS, PeNSE e dados de vendas e volume
- Modelo idade-período-coorte e a geração Z aos 25-29

A geração Z bebe menos? Na mesma idade, não

Homens −4 p.p., mulheres +6 p.p.: os sexos convergem; sem diferença por classe. Antes de investir, mais dados.

Obrigado. Perguntas?